



**UNIVERSIDAD DE SANTIAGO DE CHILE**  
**FACULTAD DE INGENIERÍA**  
**DEPARTAMENTO DE INGENIERÍA INFORMÁTICA**  
**REDES NEURONALES**  
Ayudante Ignacio Ibáñez Aliaga  
*ignacio.ibanez@usach.cl*



## Laboratorio 3: Long Short Time Memory

### Fundamento Teórico

Un sistema dinámico es aquel cuyo estado depende principalmente del tiempo. Un ejemplo de estos se aprecia en las series de tiempo, las cuales pueden ser de diferentes dominios:

- Marketing: ventas, registros de índices económicos.
- Web: clicks, logs.
- Industria: sensores (internet of things), consumo de energía.
- Biomedicina: señales fisiológicas (EEG), frecuencia cardíaca, presión arterial.
- Genoma: expresiones de genes durante ciclo celular
- Meteorología: variables del clima; temperatura, presión, viento.

Estos sistemas pueden ser modelados por medio de ecuaciones diferenciales, las cuales idealizan el comportamiento del fenómeno subyacente con principios matemáticos.

La complejidad de los sistemas dinámicos está dada principalmente por el tiempo, además puede poseer características no deseables como no linealidad. Adicionalmente se debe considerar si el fenómeno subyacente es variante o invariante en el tiempo, si cumple los principios de un proceso estacionario, esto puesto que al preprocesar los datos es necesario conocer estas características para aplicar técnicas apropiadas al momento de realizar feature extraction.

De lo anterior se desprende la necesidad de aplicar técnicas de machine learning para poder realizar:

- Predicciones del futuro (ejemplo claro es el clima).
- Control de procesos.
- Comprender los mecanismo que generan la serie de tiempo.
- Describir las características de la serie de tiempo.

## OBJETIVOS DEL LABORATORIO

El principal objetivo de este laboratorio es que el alumno logré comprender la complejidad de los sistemas dinámicos, para lo cual utilizará una red neuronal LSTM.

### Actividades

1. Escoger un paciente de la carpeta Normocapnia o Hipercapnia, en donde se mide la velocidad del flujo sanguíneo cerebral (VFSC, columna 2 del archivo) y presión arterial media (PAM, columna 3 del archivo).
2. Implementar LSTM con la librería Keras.
3. Normalizar los datos.
4. Realizar un remuestreo de los datos.
5. Implementar cross validation.
6. Realizar predicción del VFSC por medio de la PAM, buscando la cantidad de retardos de la PAM que mejoren la predicción.
7. Comparar la predicción y la señal real con el coeficiente de correlación.

### Presentación del entregable

Todas las actividades que fueron listadas en la sección anterior deben ser realizadas en jupyter notebook con python 3.\*, en donde la presentación del archivo debe ser de la siguiente manera:

1. Marco teórico de la LSTM.
2. Código.
3. Probar diferentes configuraciones de la LSTM, variando función de activación mínimo 2, función de error mínimo 2, cantidad de neuronas, capas ocultas, cantidad de iteraciones y número de retardos PAM, 30 configuraciones en total.
4. Probar las configuraciones anteriores con variaciones de remuestreo y cantidad de folds en cross validation, 9 configuraciones en total.
5. En base al coeficiente de correlación seleccionar los 3 mejores modelos, mostrar gráfico de error vs iteraciones y de señal real VFSC vs predicción.
6. Análisis de los resultados obtenidos.

7. Conclusiones.

**Fecha de entrega: 19 de Agosto del 2018**  
**Se debe enviar el archivo ipynb**